

Agentes de IA no SOC. Isso funciona?

Uma análise de um agente de IA na triagem do SOC

Rômulo Rocha
github.com/romrocha
linkedin.com/in/romrocha

YSTS 2026 !!! =)

POR QUÊ ESSA PESQUISA?

SOC stress

- 01** Alertas duplicados, semelhantes, falso-positivos, volume crescent de alertas, >80% dos alertas falso positivos, escalar somente com pessoas tem sido difícil, exaustivo e levado a níveis altos de turnover.

Falta de medição pública

- 02** “AI-powered SOC” carece de números abertos sobre eficiência, deixando a decisão restrita a provas de conceito “fechadas”, que por vezes podem ser custosas e com limitação de tempo, técnica ou dados suficientes.

Crescimento de maturidade da arquitetura agêntica

- 03** Frameworks de desenvolvimento de agentes ganharam maturidade, com ferramentas para observabilidade, customização e farta documentação pública.


LLM e RAG trazem capacidades novas

- 04** Embeddings para correlação semântica, raciocínio sobre evidências, janelas de context maiores , etc

Reasoning models vs standard models

- 05** Em Agosto/2025, surgiram os modelos de raciocínio, seriam melhores para tarefas como triagem no SOC?


01



ARQUITETURA DO AGENTE

Como funciona, o que é código e o que é LLM, desafios de engenharia.

COMO FUNCIONA UM AGENTE



Agente = LLM + memória + tools + loop de raciocínio.

Uma pilha enorme de contexto, fluxo de entradas e saídas, para que o LLM busque a resposta mais próxima dentro do seu vetor de conhecimento.

O QUE É CÓDIGO vs O QUE É LLM

Nem tudo no agente depende do modelo — boa parte da confiabilidade vem de controle determinístico.

DETERMINÍSTICO (CÓDIGO)

- ▶ **Grafo de estados (LangGraph)**
Ordem dos nós, transições, condições de saída
- ▶ **Guardrails e limites**
max_loops, recursion_limit, retry guard, clamp
- ▶ **Tool routing e execução**
ToolNode dispara, valida schema, retorna resultado
- ▶ **Vector search e ingestão**
ChromaDB query, chunking, embedding
- ▶ **Persistência e estado**
SQLite thread-local, checkpointing, schema do state
- ▶ **Output parsing e validação**
Structured output, clamp de confidence, sanity checks

NÃO-DETERMINÍSTICO (LLM)

- ▶ **Triagem e classificação do alerta**
Decidir TP/FP, severidade, confiança
- ▶ **Correlação semântica**
Agrupar alertas por narrativa, não somente por IOC
- ▶ **Decisão de qual tool chamar**
Tool_call e escolha do modelo via ReAct
- ▶ **Raciocínio e justificativa**
"Por quê esse alerta é True Positive?" — texto livre gerado
- ▶ **Interpretação de contexto (RAG)**
O que fazer com os chunks retornados do vector store?
- ▶ **Atribuição de MITRE ATT&CK**
Mapear comportamento observado para tecnica/tática

INSIGHT: Código controla o "como executa". LLM controla o "o que fazer com a informação". A confiabilidade do agente vem da qualidade das duas camadas.

STACK, GRAFOS & NÓS

LangGraph

Orquestração do agente

ChromaDB

Vector store + MiniLM-L6-v2

SQLite

Estado persistido

LangSmith

Observabilidade

OpenAI


gpt-4.1-mini / gpt-5-mini

Grafos

OUTER GRAPH (ROUND)



INNER GRAPH (UMA INVESTIGAÇÃO)



↳ edge condicional (max_loops=3)

Cada nó = `create_react_agent` (padrão canônico LangGraph)

Nós do Analista de Triage

select_seeds

= Scan da fila + priorizacao

investigate

= Abrir alerta + pivotar entidades

correlate

= Validar shared observables, temporal proximity

decide


= Registrar campanha / FP / merge

Mapeamento explícito ao fluxo humano

02

A PESQUISA

Dataset, calibração pré-experimento, vetor temporal.



DATASET — DESENHO FIXO, TEMPO COMO ÚNICA VARIÁVEL

FILOSOFIA DE DESIGN

SINTÉTICO (JSON)

Reprodutibilidade total, ground truth controlado, zero PII, isolamento de variáveis entre rounds. **O custo é abrir mão de realismo adversarial.**

THE HIVE SCHEMA

Plataforma open-source amplamente usada em SOCs corporativos. TLP, Flag, Status, SourceRef, Observable types (url, domain, ip, hostname, file, etc)

100 ALERTS / ROUND

70 ruído (FP plausíveis) + 15 ransomware finance + 15 insider threat HR. Múltiplas fontes (EDR, IdP, Email GW, DLP, proxy, scanner). MITRE com overlap proposital.

REALISMO E VERIFICAÇÃO DE ESTRUTURA

Uso de repositórios públicos para trazer realismo de conteúdo para os alertas (Sigma Rules, Microsoft Sentinel Repo, Defender etc). **12 Vendors, 47 técnicas MITRE, 215 Observáveis, 76 IOCs e 11 fontes públicas de validação.**

IOC ENRICHMENT FRACO POR ESCOLHA

Só hostname e user repetem entre alertas de uma campanha. IPs, domínios, URLs, files, hashes: ocorrência única. Agente é forçado a correlacionar por (host, user, narrativa, semântica) — dificultando o cenário.

RUÍDO DIFÍCIL + CROSS-CONTAMINATION

Sem linguagem "auto-declarada" de baixa severidade. **Entidades sobrepostas entre ruído e campanha impedem classificação trivial por isolamento.**

CAMPANHA MALICIOSA

- Ransomware LockBit Style - phishing no usuário b.smith (T1566), roubo de credenciais (T1003), movimento lateral via SMB (T1021) e ransomware no file server (T1486).
- HR Sensible Information Extraction - insider exfiltrando dados de RH — h.potter em HR-LT-118 baixa compensation fora do horário (T1078, T1530) e exfiltra via Dropbox e USB (T1567, T1052).

VARIÁVEL EXPERIMENTAL

ROUND 1

30 dias

ROUND 2

90 dias

ROUND 3

180 dias

mesma composição, campanhas, regras de enrichment

HIPÓTESE

Janela temporal cresce → âncora temporal se dilui → agente perde dimensão de correlação e precisa se apoiar mais em sinais semânticos e observáveis. Se conseguir resistir, existe uma correlação semântica de verdade.

Detalhes, ground truth e regras de geração: github.com/romrocha/research_dataset_2026 | Limitacoes e detalhes no repo.

PRÉ-EXPERIMENTO E EXPERIMENTO

PRÉ-EXPERIMENTO – AGENT FINE TUNING

- +10 rounds de calibração na fase final pré medição comparativa.
- **Decisões arquiteturais movem métricas significativamente. (+9 pp accuracy, -66% missed threats)**
- **Análise profunda dos traces no LangSmith, acoplado a um agente de IA.**
- Tipagem de Tools com Pydantic. Schemas validados e retorno útil das ferramentas estabilizam o caminho cognitivo do agente.
- Pre-Load de decisões prévias em prompt agilizam

~ \$15 Doláres de custo

O EXPERIMENTO!



- 600 alertas avaliados, em turnos de 200. Mesmo dataset canônico, mesmas tools e arquitetura. Só varia o LLM (4.1 e 5 mini) e o vetor temporal entre os rounds.
- Instrumentação completa via LangSmith. Auditoria por run de tokens, iterações, tool calls, latência por nós , custo, etc.
- Pipeline reproduzível end-to-end. (*Geração do dataset -> notebook de execução -> emissão de relatórios -> ground truth comparativo.*)
- Geração de métricas: acurácia, F1 (campaign detection e noise filtering), missed threats, latência, custo e CWTS.


~ \$6 Doláres de custo

INSIGHT: ~3x mais investimento em calibrar do que em medir. Em SOC reais, a calibração e medição deve ser constante, e os custos também.

03


RESULTADOS

Matriz, custo, latência e dados observados.




Acurácia global por round

Estresse temporal: 30 → 90 → 180 dias




Missed threats por round

Ameaças reais dispensadas como falso positivo (de 30 alertas de campanha)



Confidence reportada por campanha — flat vs bimodal

Cada ponto = 1 campanha detectada · tamanho = nº de alertas no cluster




4.1-mini reporta 85-95% para quase tudo (sem sinal útil). 5-mini é bimodal — gap observado em 65-90% separa os dois clusters.

Threshold operacional exige calibração em ambiente real.

Perfil “cognitivo” durante round 3 (180d)

6 dimensões derivadas dos traces LangSmith e métricas de avaliação · escala 0–100 normalizada



7 DIMENSÕES METACOGNITIVAS

	gpt-4.1-mini	gpt-5-mini
Investigação	breadth-first	depth-first
Agregação	40/100	65/100
Velocidade	rápido (3,64s)	deep (7,86s)
Profundidade (tool calls)	1,02x	1,39x
Diversificação (tools)	H=3,26	H=2,68
Postura	balanceado	defensivo
Cautela	73,3%	100%

Os dois agentes simulam dois perfis de N1 reconhecíveis em equipes humanas: o produtivo (4.1) e o cauteloso (5-mini).

Custo e latência

6 runs (3 rounds × 2 modelos). Reasoning custa mais por iteração — mas o total da corrida não dispara.

CUSTO POR RUN (USD)

média sobre 3 rounds · range = min → max

gpt-4.1-mini

RANGE

\$0.76 → \$0.85

média

\$0.81

P50

\$0.75

gpt-5-mini

RANGE

\$1.10 → \$1.25

média

\$1.17

P50

\$0.80

LATÊNCIA POR ITERAÇÃO (s)

tempo médio do agente decidindo 1 alert · range = min → max

gpt-4.1-mini

RANGE

0,4s - 45,7s

média

2.8s

P50 · P95

1.6s - 8.7s

gpt-5-mini

RANGE

0,8s - 66,7s

média

8.2s

P50 · P95

5s · 26s

Cache hit ~56% · reasoning tokens (5-mini) explicam 60% mais latência por iteração mas total similar por run.

INSIGHT: Diferença de +45% no custo entre gpt4.1 e 5-mini, e de +69% na latência. (total de 4h27mins) de compute time.

RESULTADOS


Oxi, o gpt4.1 é melhor?



04

CWTS

COST WEIGHTED TRIAGE SCORE. Quanto dói um falso negativo?



A acurácia esconde dois problemas estruturais

01

DESBALANCEAMENTO DE CLASSES

Acurácia recompensa o classificador preguiçoso.

Em SOC real, ruído domina. Um agente que sempre prevê "false_positive" acerta ~99% — sem fazer trabalho cognitivo. Bayes mostra que PPV depende da base rate, não da TPR.

Axelsson (2000) — The Base-Rate Fallacy and the Difficulty of Intrusion Detection Systems

02

ASSIMETRIA DE CUSTO

FN e FP não custam a mesma coisa. Acurácia trata como 1:1.

FP custa horas de analista. FN deixa ameaça passar — dwell time, incidente consumado. Literatura sugere razões de 10:1 a 100:1.

Elkan (2001) · Stolfo et al. (2000) · Gaffney & Ulvila (2001)

▼ **CWTS endereça os dois — normalização cobre (1), peso k cobre (2)**

CWTS – custo assimétrico vira score

Exemplificação do cálculo do custo assimétrico do SOC.

A INTUIÇÃO:

Cada FP custa **1 ponto**.

Cada FN custa **50 pontos**.

Vence quem tem **menor custo total**.

"O k=50 não é meu — é o midpoint da faixa documentada por Gaffney & Ulvila há 24 anos. Eles trouxeram teoria da decisão para IDS em 2001. Estou aplicando o framework deles em agentes de IA — não inventando nada, só estendendo."

EXEMPLO APLICADO AO ROUND 1:

$$\text{gpt-4.1-mini} = 18\text{FP} \times 1 + 8\text{FN} \times 50 = 418$$

$$\text{gpt-5-mini} = 35\text{FP} \times 1 + 0\text{FN} \times 50 = 35$$

$$\text{Pior caso} = 70 \times 1 + 30 \times 50 = 1570$$


$$\text{CWTS} = 1 - \text{custo} / \text{pior_caso}$$

$$4.1\text{-mini} \rightarrow 73,4\%$$

$$5\text{-mini} \rightarrow 97,8\%$$


A curva CWTS(k) — Round 1 (30 dias)

Cenário leve — ambos os modelos com FN=0. 4.1-mini vence em todos os k (menor over-aggregation).



A curva CWTs(k) — Round 3 (180 dias)


Banda de incerteza = penalidade de produção (+3 FN). Crossover observado em $k=2,1$; conservador em $k=3,1$.



05

Fechamento

Insights e uso prático de agentes na triagem



5 aprendizados da pesquisa

01

TRIAGEM AUMENTADA FUNCIONA

Agente de nível construído com LangGraph + tools tipadas + observabilidade entrega resultado mensurável. 6 runs, 600 alerts com acurácia superior a >70% sustentada nos 3 rounds , além de CWTS maior que 90% para K=50. Todas as campanhas maliciosas foram detectadas.

02

MODELOS DIFERENTES, NÃO HÁ UM VENCEDOR

Trocar de gpt-4.1-mini para gpt-5-mini, mudou o estilo cognitivo. Modelos de raciocínio funcionam fundamentalmente diferente, escolha de modelo é escolha de viés operacional.

03

REASONING MODEL REPORTA CONFIANÇA CALIBRADA, STANDARD NÃO

O gpt5-mini distribuiu a confiança em dois clusters bimodais, ele sabe quando duvidar da informação que produz. O 4.1-mini reporta uma confiança flat (85%-95%) o que pode ser um desafio para o nível 2 em priorizar.

04

CONFIABILIDADE DO AGENTE VEM DA ENGENHARIA, NÃO DO MODELO

Pre-tuning de tools tipadas (Pydantic), pré-load de decisões em prompt, observabilidade rigorosa (LangSmith), ground truth determinístico. +9 pp de accuracy vieram só dessa fase, antes de qualquer benchmark. Custo: \$15. Engineering > prompt engineering.

05

MÉTRICAS PRECISAM RESPEITAR A ASSIMETRIA DO SOC

Acurácia trata FP e FN como iguais. SOC real não — perder uma ameaça custa 50× mais que investigar ruído. CWTS dá vocabulário matemático para essa assimetria.

Antes de colocar IA no seu SOC

VARIÂNCIA PRODUTIVA

Qualidade do agente depende de fine-tuning, embeddings, prompts e dados reais. Benchmark sintético é piso teórico, não garantia.

Lembre-se
GIGO – Garbage in, Garbage out.

Métricas vistas aqui (77% / 0 missed) podem cair 10-30 pp em SOC real sem calibração específica.

COMPLEXIDADE DA PIPELINE

A complexidade do seu SOC vai aumentar. Quem vai revisar o output do agente? Como será feito esse finetuning? Que tipo de guardrails vai definir? Como medir que melhorou ou piorou?

É fundamental ter engenharia de IA ativa no time.

Custo de revisão precisa entrar no ROI. Pipeline cresce: observabilidade + auditoria + retraining contínuo.

VIÉS DE CONFIRMAÇÃO

Vimos que modelos standard reportam alta confiança em quase todos os resultados, com uma história coerente, analistas podem cair no viés de confirmação. O uso de modelos que imprimem confiança distribuída pode ajudar nessa análise mais cautelosa.

Treinar humanos a DUVIDAR do agente é parte do projeto. UX precisa mostrar incertezas, não esconder.

INSIGHT: Não é por o agente acertar muito que ele deveria operar sozinho. Aonde ele erra são exatamente o que humano cobre.

Augmented, not autonomous. (yet?)

✓ PRONTO PARA USO HOJE

Baixo risco se errar. Humano valida output natural do workflow.

- Documentação automática de alertas (descrição, contexto, MITRE mapping)
- Enriquecimento (IOC lookups, geo, ATT&CK tactic, threat intel)
- Correlação determinística (mesma hash, mesma URL, mesmo IP)
- Sumarização de cases longos para handover entre turnos

⚠ CAUTELA E SUPERVISÃO

Erros caros. Humano sênior valida cada decisão.

- Triagem L1 completa autônoma (action-reason desync, over-aggregation)
- Decisão final de FP / escalation sem revisão humana
- Resposta automática a incidentes (containment, isolation)
- Multi-agent autônomo sem observabilidade entre etapas

DISCIPLINA DE ENGENHARIA — NÃO-NEGOCIÁVEL

- Observabilidade ponta-a-ponta (LangSmith, traces, métricas)
- Monitoria contínua (purity, recall, missed, latência, custo)
- Versionamento de prompts e schemas
- Auditoria periódica de qualidade das decisões (hallucinations, sycophancy, drift)

FINAL BOSS INSIGHT: *Se você não pode auditar o agente, você não deve usar o agente. SOC é disciplina, não experimento.*

Obrigado. Q&A

Rômulo Rocha – linkedin.com/in/romrocha
github.com/romrocha